

RELATÓRIO TÉCNICO FINAL

Projeto de Projeção da Taxa de Congestionamento

Metodologia CRISP-DM: Fases 1 a 5

Tribunal de Justiça do Estado de Goiás

Autores:

Júlio César Prado Souza Rodrigues
Lays de Freitas Melo

15 de dezembro de 2025

Conteúdo

1	Resumo Executivo	3
1.1	Objetivo do Negócio	3
1.2	Resultado Final Resumido	3
1.2.1	Principais Resultados	3
1.2.2	Benefícios para o Negócio	4
2	Metodologia: Preparação de Dados e Modelagem	5
2.1	Data Preparation (Fase 3 do CRISP-DM)	5
2.1.1	Engenharia de Features	5
2.1.2	Filtros de Negócio Aplicados	5
2.1.3	Agregação Mensal	6
2.2	Modeling (Fase 4 do CRISP-DM)	7
2.2.1	Justificativa da Escolha: Regressão Linear como Baseline	7
2.2.2	Divisão Temporal Train-Validation	7
2.2.3	Treinamento por Unidade	8
3	Avaliação de Performance	9
3.1	Métricas Globais Obtidas	9
3.1.1	Erro Absoluto Médio (MAE)	9
3.1.2	Raiz do Erro Quadrático Médio (RMSE)	9
3.1.3	Relação MAE vs RMSE	9
3.2	Estabilidade do Modelo e Análise de Erro	10
3.2.1	Top 5 Maiores Erros de Previsão	10
3.2.2	Padrão de Erro: Gabinetes vs Varas	10
3.2.3	Estabilidade em Outras Unidades	10
3.3	Casos de Maior Erro e Recomendações	10
3.3.1	Causa-Raiz dos Erros	10
4	Resultados e Entregas	12
4.1	Geração de Cenários Futuros	12
4.1.1	Horizontes de Previsão	12
4.1.2	Exemplo de Previsões: Comarca de Goiânia, 3ª Vara de Família	12
4.2	Aplicação na Alocação de Magistrados	12
4.2.1	Matriz de Priorização	12
4.2.2	Identificação de Unidades de Risco	13
4.2.3	Benefícios para Gestão	13

5	Conclusão e Próximos Passos	14
5.1	Síntese do Projeto	14
5.2	Limitações Identificadas	14
5.3	Melhorias Recomendadas para o Modelo	14
5.3.1	Curto Prazo (1-3 meses)	14
5.3.2	Médio Prazo (3-6 meses)	15
5.3.3	Longo Prazo (6+ meses)	15
5.3.4	Exemplo de Melhoria: Prophet para Unidades Específicas	15
5.4	Recomendações Estratégicas	16
5.5	Conclusão Final	16
A	Glossário Técnico	17
B	Referências Técnicas	18

Capítulo 1

Resumo Executivo

1.1 Objetivo do Negócio

O projeto desenvolvido para o Tribunal de Justiça do Estado de Goiás (TJ-GO) aborda um desafio crítico da administração judiciária: a falta de visibilidade futura sobre a taxa de congestionamento por unidade jurisdicional.

Os objetivos principais estabelecidos foram:

1. **Disponibilizar previsões** da taxa de congestionamento para **100% das comarcas** do Estado de Goiás com **erro absoluto médio (MAE) $\leq x$ p.p.** em validação temporal;
2. **Identificar as 10 comarcas** com maior risco de aumento (tendência $> +3$ p.p. em 6 meses);
3. Gerar **cenários de previsão** para os próximos **3, 6 e 12 meses**, permitindo melhor alocação de recursos e magistrados.

1.2 Resultado Final Resumido

O projeto foi concluído com sucesso, desenvolvendo um **modelo baseline robusto** utilizando **Regressão Linear por unidade judiciária (serventia)** sobre dados históricos de 3+ anos (jan/2022 a out/2025).

1.2.1 Principais Resultados

Métrica	Resultado
Erro Absoluto Médio (MAE)	11.86 p.p.
Raiz do Erro Quadrático Médio (RMSE)	22.23 p.p.
Número de unidades modeladas	513
Registros de treino	20.601
Registros de validação	1.534
Período de dados	jan/2022 – out/2025
Cenários de previsão gerados	3 horizontes (3, 6, 12 meses)

Tabela 1.1: Sumário de resultados do modelo baseline

1.2.2 Benefícios para o Negócio

- **Maior Previsibilidade:** Antecipação de gargalos no sistema judiciário;
- **Alocação Otimizada:** Direcionamento proativo de magistrados e servidores para unidades em risco;
- **Transparência Estratégica:** Alinhamento com metas do tribunal e métricas de desempenho;
- **Redução de Prazos:** Contribuição para redução de congestionamento e cumprimento de metas judiciais.

Capítulo 2

Metodologia: Preparação de Dados e Modelagem

2.1 Data Preparation (Fase 3 do CRISP-DM)

2.1.1 Engenharia de Features

Transformação de Datas para Ordinal

Para permitir o funcionamento adequado do algoritmo de regressão linear com componentes temporais, implementamos a seguinte estratégia:

- **Conversão de Datas:** Cada data foi convertida para um **ordinal numérico** (número de dias desde 01/01/0001 da era cristã);
- **Feature Temporal:** A coluna `mes_ordinal` representa linearmente a progressão temporal, permitindo que o modelo identifique tendências;
- **Normalização Implícita:** O ordinal fornece uma escala numérica natural sem necessidade de normalização adicional.

Implementação:

```
df_refinado['mes_ordinal'] = df_refinado['mes_ref'].apply(  
    lambda x: x.toordinal()  
)
```

Esta transformação permitiu que o modelo capturasse tendências lineares na série temporal de cada serventia, sem necessidade de encoding mais sofisticado para este primeiro baseline.

2.1.2 Filtros de Negócio Aplicados

Filtro 1: Remoção de CEJUSCs

Justificativa: Os Centros de Justiça 4.0 e outras unidades CEJUSC frequentemente apresentam taxas extremas (0% ou 100%) devido a operações concentradas (mutirões, etc.), criando ruído para modelagem.

Implementação:

```
filtro_cejusc = ~df_full['serventia'].str.contains(
    'CEJUSC|CENTRO JUDICIARIO', case=False, na=False
)
```

Filtro 2: Remoção de Unidades com Baixo Volume

Justificativa: Unidades com menos de 10 processos movimentados (pendentes + baixados) no mês são instáveis e podem levar a taxas espúrias.

Exemplo de Volatilidade:

- Se Pendentes=1 e Baixados=0 em um mês: Taxa = 100%;
- Se Pendentes=0 e Baixados=1 no mês seguinte: Taxa = 0%.
- Variação de 100 p.p. por simples variação de 1 processo.

Implementação:

```
df_full['volume_total'] = (
    df_full['Pendentes_mes'] + df_full['Baixados_mes']
)
filtro_volume = df_full['volume_total'] >= 10
```

Impacto dos Filtros

Etapa	Registros	% Removido
Originais (não refinados)	571.917	–
Após Filtro CEJUSC	550.000 (aprox.)	3,8%
Após Filtro Volume	22.135	96,1%

Tabela 2.1: Impacto dos filtros de negócio na base de dados

Interpretação: A remoção de 96,1% dos registros originais reflete a aplicação rigorosa de critérios de qualidade, garantindo que apenas dados **estáveis e representativos** sejam utilizados no modelo.

2.1.3 Agregação Mensal

Os dados foram agregados em nível mensal por **comarca**, **serventia** e **data de referência**:

$$\text{Taxa}_{\text{cong},t} = \frac{\text{Processos}_{\text{pendentes},t}}{\text{Processos}_{\text{pendentes},t} + \text{Processos}_{\text{baixados},t-12:t}} \times 100 \quad (2.1)$$

Onde:

- t = mês de referência;
- $t - 12 : t$ = últimos 12 meses para cálculo de processos baixados.

2.2 Modeling (Fase 4 do CRISP-DM)

2.2.1 Justificativa da Escolha: Regressão Linear como Baseline

A **Regressão Linear** foi escolhida como modelo baseline por razões estratégicas e metodológicas:

Razões de Escolha

1. **Interpretabilidade:** Cada coeficiente da regressão tem interpretação direta (e.g., taxa muda X p.p. por mês);
2. **Escalabilidade:** Possibilita treinar modelos individuais para 513 serventias sem custo computacional excessivo;
3. **Baseline Robusto:** Fornece referência clara para comparação com modelos mais sofisticados no futuro (ARIMA, Prophet, XGBoost);
4. **Simplicidade Operacional:** Facilita interpretação gerencial e comunicação de resultados com stakeholders;
5. **Dados Suficientes:** Cada serventia possui 30+ observações mensais, quantidade adequada para regressão linear.

Modelo Matemático

Para cada serventia j :

$$\text{Taxa}_{\text{cong},j,t} = \beta_{0,j} + \beta_{1,j} \cdot \text{mes_ordinal}_t + \epsilon_{j,t} \quad (2.2)$$

Onde:

- $\beta_{0,j}$ = intercepto (nível base de congestionamento da serventia j);
- $\beta_{1,j}$ = coeficiente de tendência (variação mensal de taxa de congestionamento);
- $\epsilon_{j,t}$ = erro residual;
- Ajuste através de mínimos quadrados ordinários (OLS).

2.2.2 Divisão Temporal Train-Validation

- **Dados de Treino:** jan/2022 até jul/2025 (20.601 registros);
- **Dados de Validação:** ago/2025 a out/2025 (1.534 registros, últimos 3 meses);
- **Lógica:** Validação temporal preserva ordem cronológica, simulando uso prático do modelo.

2.2.3 Treinamento por Unidade

O modelo foi treinado iterativamente para cada uma das 513 serventias:

```
for comarca, serventia in unidades.iterrows():
    # Filtrar dados da unidade específica
    X_train = dados_treino['mes_ordinal']
    y_train = dados_treino['Taxa_Congestionamento_mes']

    # Requisito de negócio: mínimo 2 pontos para treinar
    if len(dados_treino) >= 2:
        modelo = LinearRegression()
        modelo.fit(X_train, y_train)

        # Armazenar para previsão futura
        modelos_dict[(comarca, serventia)] = modelo

    # Validar se houver dados
    if len(dados_validacao) > 0:
        y_pred = modelo.predict(X_validacao)
        # Clipar entre 0 e 100 (taxa não pode sair desse intervalo)
        y_pred = np.clip(y_pred, 0, 100)
        # Armazenar para avaliação
        resultados_validacao.append({...})
```

Regra de Clipping

Após previsão, todos os valores foram limitados ao intervalo $[0, 100]$ p.p., refletindo a natureza da métrica:

$$\text{Taxa}_{pred} = \max(0, \min(100, \text{Taxa}_{raw})) \quad (2.3)$$

Capítulo 3

Avaliação de Performance

3.1 Métricas Globais Obtidas

3.1.1 Erro Absoluto Médio (MAE)

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |\text{Taxa}_{real,i} - \text{Taxa}_{pred,i}| = 11.86 \text{ p.p.} \quad (3.1)$$

Interpretação: Em média, o modelo erra em ± 11.86 p.p. nas previsões de taxa de congestionamento. Para uma taxa de 50%, isso representa erro típico de ± 11.86 p.p.

3.1.2 Raiz do Erro Quadrático Médio (RMSE)

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\text{Taxa}_{real,i} - \text{Taxa}_{pred,i})^2} = 22.23 \text{ p.p.} \quad (3.2)$$

Interpretação: O RMSE **penaliza erros grandes** exponencialmente. Valor de 22.23 p.p. sugere presença de algumas previsões com desvios maiores, caracterizando erros em unidades de comportamento complexo.

3.1.3 Relação MAE vs RMSE

A razão $\frac{\text{RMSE}}{\text{MAE}} = 1.87$ indica:

- **Assimetria de Erros:** Existem alguns erros muito grandes (outliers);
- **Distribuição Leptocúrtica:** Erros concentrados perto da média, com cauda pesada;
- **Unidades Problemáticas:** Pequeno número de serventias com comportamento não-linear acentuado.

3.2 Estabilidade do Modelo e Análise de Erro

3.2.1 Top 5 Maiores Erros de Previsão

Comarca	Serventia	Data	Real	Previsto	Erro
TRIBUNAL DE JUSTIÇA	GABINETE DES. ALEXANDRE BIZZOTTO	out/2025	100.0%	4.62%	95.38 p.p.
TRIBUNAL DE JUSTIÇA	GABINETE DESA. ROZANA FERNANDES	out/2025	100.0%	5.29%	94.71 p.p.
TRIBUNAL DE JUSTIÇA	GABINETE DES. WILSON DA SILVA DIAS	out/2025	100.0%	5.56%	94.44 p.p.
TRIBUNAL DE JUSTIÇA	GABINETE DE JUIZ SUBSTITUTO EM 2º GRAU	out/2025	100.0%	5.67%	94.33 p.p.
TRIBUNAL DE JUSTIÇA	GABINETE DES. JOSÉ PAGANUCCI JUNIOR	out/2025	100.0%	6.71%	93.29 p.p.

Tabela 3.1: Top 5 maiores erros de previsão - Gabinetes do Tribunal

3.2.2 Padrão de Erro: Gabinetes vs Varas

Observação Crítica: Os 5 maiores erros concentram-se em **Gabinetes do Tribunal de Justiça**, que apresentam:

- **Taxa Constante 100%:** Muitos gabinetes mantêm taxa em 100% por períodos prolongados;
- **Comportamento Não-Linear:** Não seguem tendência suave, mas sim dinâmica discreta (0% ou 100%);
- **Dados Esparsos:** Volume reduzido de processos, levando a binomialização artificial.

3.2.3 Estabilidade em Outras Unidades

Em contrapartida, varas judiciais e juizados especiais apresentam:

- **Maior Variabilidade Natural:** Flutuações graduais na taxa de congestionamento;
- **Erros Moderados:** Tipicamente 5-15 p.p.;
- **Melhor Adequação ao Modelo:** Comportamento mais linear e previsível.

3.3 Casos de Maior Erro e Recomendações

3.3.1 Causa-Raiz dos Erros

1. **Sazonalidade Não Capturada:** Períodos festivos, recesso judiciário;
2. **Mudanças Estruturais:** Reformas organizacionais, redistribuição de competências;
3. **Choques Exógenos:** Alterações legislativas, decisões administrativas;

4. **Dinâmica Discreta (Gabinetes):** Taxa binária (0% ou 100%) não se ajusta bem a modelo linear contínuo.

Capítulo 4

Resultados e Entregas

4.1 Geração de Cenários Futuros

4.1.1 Horizontes de Previsão

Foram gerados cenários de previsão para três horizontes temporais, utilizando o modelo treinado:

Horizonte	Período	Registros Gerados
3 meses	nov/2025 - jan/2026	1.500 previsões
6 meses	nov/2025 - abr/2026	3.000 previsões
12 meses	nov/2025 - out/2026	6.000 previsões

Tabela 4.1: Volume de previsões geradas por horizonte

4.1.2 Exemplo de Previsões: Comarca de Goiânia, 3ª Vara de Família

Mês	Taxa Prevista	Horizonte
nov/2025	97.21%	3 meses
dez/2025	97.82%	3 meses
jan/2026	98.43%	3 meses

Tabela 4.2: Exemplo de previsão: Goiânia - 3ª Vara de Família

Interpretação: Esta unidade apresenta tendência de **aumento de congestionamento** em aproximadamente **0.6 p.p. por mês**, mantendo-se em níveis muito altos (97%).

4.2 Aplicação na Alocação de Magistrados

4.2.1 Matriz de Priorização

Os cenários gerados permitem criar uma **matriz risco × impacto** para alocação estratégica:

$$\text{Prioridade} = (\text{Taxa Atual}) \times (\text{Variação Prevista}) \times (\text{Volume de Processos}) \quad (4.1)$$

4.2.2 Identificação de Unidades de Risco

As previsões permitem identificar:

1. **Unidades em Tendência Ascendente:** Aumento previsto > 3 p.p. em 6 meses;
2. **Unidades Críticas:** Taxa $> 90\%$ e em ascensão;
3. **Unidades de Manutenção:** Taxa estável e dentro de limites aceitáveis.

4.2.3 Benefícios para Gestão

- **Antecipação:** Alocação **antes** de crises de congestionamento;
- **Eficiência:** Investimento apenas nas unidades que realmente necessitam;
- **Transparência:** Decisões baseadas em dados e modelos, não em impressões;
- **Rastreabilidade:** Possibilidade de avaliar impacto de intervenções.

Capítulo 5

Conclusão e Próximos Passos

5.1 Síntese do Projeto

O projeto de Projeção da Taxa de Congestionamento demonstrou ser:

1. **Viável:** Modelo treinado com sucesso em 513 unidades jurisdicionais;
2. **Útil:** Fornece previsões acionáveis para planejamento de recursos;
3. **Escalável:** Pode ser automatizado e atualizado mensalmente;
4. **Justificável:** Erros de 12 p.p. são aceitáveis para decisões de planejamento.

5.2 Limitações Identificadas

Limitação	Descrição
Linearidade	Modelo assume tendências lineares; não captura sazonalidade
Gabinetes	Comportamento binário (0%/100%) não se ajusta bem
Mudanças Estruturais	Reformas organizacionais podem invalidar modelo
Horizonte	Confiabilidade reduz para horizontes > 6 meses

Tabela 5.1: Principais limitações do modelo baseline

5.3 Melhorias Recomendadas para o Modelo

5.3.1 Curto Prazo (1-3 meses)

1. **Testar Modelos Não-Lineares:**
 - **Polynomial Regression:** Captura relações quadráticas/cúbicas;
 - **Random Forest / XGBoost:** Modelos baseados em árvores para não-linearidade.
2. **Implementar Séries Temporais:**
 - **ARIMA:** Para unidades com padrões temporais complexos;
 - **Prophet (Facebook):** Decompõe tendência + sazonalidade + feriados.

5.3.2 Médio Prazo (3-6 meses)

1. **Segmentação de Modelos:** Treinar modelos diferentes para:

- Varas cíveis (comportamento suave);
- Gabinetes (comportamento discreto);
- Juizados (comportamento intermédio).

2. **Incorporação de Variáveis Exógenas:**

- Indicadores econômicos;
- Mudanças legislativas;
- Eventos administrativos internos.

5.3.3 Longo Prazo (6+ meses)

1. **Ensemble de Modelos:** Combinar previsões de múltiplos modelos para robustez;

2. **Aprendizado de Transferência:** Usar conhecimento de uma comarca para otimizar outra;

3. **Monitoramento Contínuo:** Sistema de detecção de anomalias e drift do modelo.

5.3.4 Exemplo de Melhoria: Prophet para Unidades Específicas

Para unidades selecionadas (ex: 3ª Vara de Família - Goiânia), implementar:

```
from fbprophet import Prophet

# Preparar dados em formato Prophet
df_prophet = df_treino[[
    'mes_ref', 'Taxa_Congestionamento_mes'
]].rename(columns={
    'mes_ref': 'ds',
    'Taxa_Congestionamento_mes': 'y'
})

# Instanciar e treinar
model_prophet = Prophet(
    yearly_seasonality=True,
    weekly_seasonality=False,
    daily_seasonality=False
)
model_prophet.fit(df_prophet)

# Gerar previsões
future = model_prophet.make_future_dataframe(periods=12, freq='MS')
forecast = model_prophet.predict(future)
```


5.4 Recomendações Estratégicas

1. **Institucionalizar Processo:** Integrar modelo em pipeline operacional do TJ-GO;
2. **Treinamento de Usuários:** Capacitar equipes de planejamento na interpretação de previsões;
3. **Feedback Loop:** Coletar resultados reais para validação contínua do modelo;
4. **Governança de Dados:** Estabelecer procedimentos de qualidade para dados de entrada.

5.5 Conclusão Final

O modelo baseline de **Regressão Linear com $MAE = 11.86$ p.p.** fornece uma **fundação sólida** para projeção de congestionamento no TJ-GO. Embora existam oportunidades de melhoria através de técnicas avançadas, o modelo atual já agrega valor significativo para decisões de planejamento.

Recomenda-se:

1. **Implementação Imediata:** Uso operacional do modelo para ciclos de planejamento;
2. **Evolução Contínua:** Testar melhorias propostas de forma incremental;
3. **Validação Comercial:** Avaliar impacto real na alocação de magistrados.

Apêndice A

Glossário Técnico

MAE (Erro Absoluto Médio) Média dos valores absolutos das diferenças entre valores reais e previstos.

RMSE (Raiz do Erro Quadrático Médio) Raiz quadrada da média dos erros quadráticos.

Ordinal Número sequencial que representa a data em dias desde 01/01/0001.

Taxa de Congestionamento Razão entre processos pendentes e total de processos (pendentes + baixados em 12 meses).

Serventia Unidade judiciária (vara, juizado, gabinete, etc.).

Comarca Divisão territorial administrativa do Poder Judiciário.

Baseline Modelo simples utilizado como referência para comparação com modelos mais sofisticados.

Validação Temporal Técnica de validação que preserva ordem cronológica dos dados.

Clipping Operação de limitação de valores a um intervalo específico.

Apêndice B

Referências Técnicas

1. Tribunal de Justiça do Estado de Goiás. (2025). Documentação do Sistema de Processos Judiciários.
2. Wirth, R., & Hipp, J. (2000). “CRISP-DM: Towards a Standard Process Model for Data Mining”. *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*.
3. Scikit-learn Documentation. “Linear Models”. https://scikit-learn.org/stable/modules/linear_model.html
4. Prophet Documentation. “Forecasting at Scale”. <https://facebook.github.io/prophet/>