



APRENDIZAGEM DE MÁQUINA

Otávio Calaça Xavier



PODER JUDICIÁRIO
Tribunal de Justiça do Estado de Goiás

 Programa de
Residência em TI

Aula 4

Aprendizado Supervisionado

INF

INSTITUTO DE
INFORMÁTICA



UFMG
UNIVERSIDADE
FEDERAL DE GOIÁS



PODER JUDICIÁRIO


Tribunal de Justiça do Estado de Goiás



Programa de
Residência em TI

Algoritmos Supervisionados

Machine learning é sobre extração de padrões nos dados para que esses padrões possam ser utilizados na resolução de problemas.




Algoritmos Supervisionados - Extração de padrões



Em um problema de aprendizagem supervisionada **SEMPRE** deve existir uma base rotulada com as **features** + **target** (classes ou valores).

Na prática, o desafio é definir as features e o target do problema...



Algoritmos Supervisionados - Extração de padrões

as *features* podem ser **categóricas**, **discretas** ou **contínuas**. Isso quando são estruturadas...

Cliente	Emprego	Idade	Renda	Cartões	Resposta (alvo)
David	Professor	37	50	2	Sim
John	Professor	35	35	3	Sim
Rachael	Programador	22	50	2	Não
Ruth	Gerente de TI	63	200	1	Não
Jefferson	Gerente de TI	59	170	1	Não
Norah	Professor	25	40	4	Sim

Algoritmos Supervisionados - Extração de padrões

... e quando não são?

**DADOS
ESTRUTURADOS**




bases de dados

**DADOS NÃO
ESTRUTURADOS**




Uma **imagem** é uma matriz de pixels que são números...



Algoritmos Supervisionados - Extração de padrões

Um áudio pode ser representado também por uma matriz como o espectrograma....



Algoritmos Supervisionados - Extração de padrões

Extração de padrões em texto

verbal, rapidamente se encaminhando para um desfecho de agressão física, do que joga. De memórias desta idade se constituem em turnos, onde têm que enfrentar, além das tensões internas, brigas e ataques contínuos das outras turnos, sempre constituídos por inimigos. É um clima geral de medo, especialmente para aqueles que se sentem, por qualquer razão, com menos capacidade para enfrentar as brigas e tensões que se exprimem como violência física direta.

A maioria dos meninos consegue desempenhar razoavelmente este padrão de comportamento evitado, que não se pode mesmo dizer com prioridade da endo vên, e nem mesmo se correspondendo ao ansio da maioria. Da experiência clínica e pessoal, nunca ouvi ninguém contar deste período da vida com alegria e orgulho, apenas, sua sempre associada a situações de medo, de experiências homossexuais bastante contrariadoras, cuja lembrança funciona como um fantasma

verbal, rapidamente se encaminhando para um desfecho de agressão física, do que joga. De memórias desta idade se constituem em turnos, onde têm que enfrentar, além das tensões internas, brigas e ataques contínuos das outras turnos, sempre constituídos por inimigos. É um clima geral de re-

verbal, rapidamente se encaminhando para um desfecho de agressão física, do que joga. De memórias desta idade se constituem em turnos, onde têm que enfrentar, além das tensões internas, brigas e ataques contínuos das outras turnos, sempre constituídos por inimigos. É um clima geral de medo, especialmente para aqueles que se sentem, por qualquer razão, com menos capacidade para enfrentar as brigas e tensões que se exprimem como violência física direta.

A maioria dos meninos consegue desempenhar razoavelmente este padrão de comportamento evitado, que não se pode mesmo dizer com prioridade da endo vên, e nem mesmo se correspondendo ao ansio da maioria. Da experiência clínica e pessoal, nunca ouvi ninguém contar deste período da vida com alegria e orgulho, apenas, sua sempre associada a situações de medo, de experiências homossexuais bastante contrariadoras, cuja lembrança funciona como um fantasma

Um bom número deles são mais sucedidos neste modo particular de viver estes anos em nossa mesa. São terrivelmente ridicularizados pelos outros. São tratados como seres desprezíveis, similares às meninas. Alguns deles se retraem do grupo, se trancam em casa, letargias. Outros, continuam participando do grupo, no papel de "maricas", objetos de toda a tipo de chacota e ridicularização, fortemente ameaçados com terríveis humilhações físicas dos mais fortes sobre eles. Vale a pena concluir já - e o isto voltaremos depois - que se estabelece claramente uma correlação entre competência agressiva e competência sexual. Os mais violentos e capazes de agredir mais livremente suas agressividade em sua vida.

Com a puberdade e início da adolescência (13-17 anos) volta o interesse pelos realismo. O lado mais interessante desta reafirmação de importância e significado da mesma é que o desprezo rapidamente se transforma em medo. É este é um fato curioso, pois os meninos se transformam em ameaçados não só para a abordagem sexual, mas também para fins de namoro ingênuo. É provável que este medo tenha relação direta com uma sensação de incompetência como macho, que é o que acaba restando em quase todo o mundo como resultado do terrível período da infância. De todos as aproximações, a sexual é a mais tensa (além de também desajustada) e o "pôr-se à prova", testar-se como homem. Ninguém está preparado para isto. E se fracassarem? É uma tragédia que tem que ser evitada a qualquer custo. E tem que ser evitada para si mesmo, mas também (num nível de importância comparável) para fins de reputação perante o grupo, cuja importância

ama de
Residência em TI

INF
INSTITUTO DE
INFORMÁTICA



PODER JUDICIÁRIO
Tribunal de Justiça do Estado de Goiás

Fundamentos da Busca Lexical



A recuperação lexical encontra documentos com base em palavras-chave e na frequência com que aparecem.

Como funciona?

- Utiliza **Índice Invertido**
- Estrutura de dados principal que mapeia **termos** (palavras) para os **documentos** que os contêm, sendo a base para a busca textual de **alta performance** em bancos de dados.

Fundamentos da Busca Lexical



Como se mede a relevância?

- **TF-IDF:** $tfidf(t, d, D) = tf(t, d) \cdot idf(t, D)$ - onde $tf(t, d)$ é a frequência do termo no documento e $idf(t, D)$ é a raridade do termo em toda a coleção de documentos.
- **BM25:** considerada uma técnica clássica e mais robusta, que evolui o TF-IDF ao considerar o **tamanho dos documentos** para evitar distorções. Atualmente o BM25 é otimizado e implementado diretamente em SGBDs relacionais por meio de índices **Full-Text**.

Busca Full-Text na Prática



A Evolução dos Bancos de Dados

- Estamos testemunhando a **evolução dos SGBDs tradicionais** para bancos de dados **multimodais**.
- Estes sistemas são projetados para gerenciar e consultar dados **lexicais, vetoriais e estruturados** de forma nativa e eficiente.



Busca Full-Text na Prática



Otimização Dentro do Banco de Dados

- Técnicas lexicais clássicas como o BM25, que antes eram domínio de motores de busca, agora são otimizadas **diretamente dentro dos SGBDs relacionais**.
- Essa otimização é realizada via **índices *Full-Text***, que implementam a estrutura de um **índice invertido** de forma eficiente.

Busca Full-Text na Prática



Exemplo Prático: PostgreSQL

- O PostgreSQL é um excelente exemplo dessa capacidade, utilizando **índices especializados** para acelerar buscas textuais.
- Os principais tipos de índice para essa finalidade são:
 - **GIN** (Generalized Inverted Index)
 - **GIST** (Generalized Search Tree)



A Revolução dos *Embeddings*



Além das Palavras-Chave: A Busca por Significado

- Enquanto a busca lexical foca em **palavras**, a busca vetorial foca em **similaridade semântica** ou significado.
- A ascensão dos *embeddings* impulsionou essa nova capacidade de busca por **similaridade vetorial**.




A Revolução dos *Embeddings*



O que são *Embeddings*?

- São **representações numéricas** (vetores) de dados não estruturados como palavras ou frases, imagens, som, etc.
- No **espaço vetorial** gerado, conceitos semanticamente próximos são posicionados perto um do outro.



A Revolução dos *Embeddings*



Word2Vec (2013):

- Um dos **pioneiros** na representação de palavras como vetores.
- Famoso por capturar relações como:

$\text{vetor('Rei')} - \text{vetor('Homem')} + \text{vetor('Mulher')} \approx \text{vetor('Rainha')}$

- Limitação: Focado em **palavras**, não no significado de sentenças completas.



A Revolução dos *Embeddings*




Sentence-BERT (SBERT) (2019):

- Uma evolução que gera embeddings para **sentenças inteiras** ou parágrafos.
- Foi projetado para ser altamente eficiente em tarefas de comparação de similaridade textual em larga escala.
- Frases como *"Um homem está comendo pizza"* e *"Uma pessoa está se alimentando"* terão vetores muito próximos.



KNN - K

Vizinhos mais próximos




KNN - k-nearest neighbors



KNN é um dos modelos preditivos mais simples que existem. Não possui premissas matemáticas e parte da ideia de que “**pontos próximos tem o mesmo comportamento**” ou “*Diga-me com quem andas que eu direi quem és!*”

Necessita apenas de:

- Uma noção de distância
- Um tamanho de vizinhança **K**




KNN - k-nearest neighbors

O **treinamento** do KNN é “decorar a base de treino”

A **inferência** é “buscar” os K indivíduos mais próximos e **fazer uma votação**

Qual K usar?







KNN - k-nearest neighbors

O tamanho do K define a fronteira de decisão do modelo de classificação.
O que acontece se $K=1$ ou $K=(\text{total de registros})$?

nearest neighbour ($k = 1$)




20-nearest neighbour





KNN - k-nearest neighbors

O KNN pode ser usado para regressão?



Uma vez que recuperamos os vizinhos mais próximos, podemos usá-los para qualquer tarefa exploratória.

- Podemos calcular a média, mediana ou qualquer outra estatística dos vizinhos e inferir no novo dado

Índices de Busca Vetorial Aproximada (ANN)



- ANN (*Approximate Nearest Neighbors*) $\approx$ kNN (*k-Nearest Neighbors*)
- Como a busca vetorial exata é lenta, a indústria usa a Busca Aproximada (ANN), que troca uma pequena margem de precisão por uma **velocidade muito maior**.
- Essa busca é integrada a bancos de dados via extensões como o **pg_vector**, que por sua vez utiliza algoritmos de indexação vetorial como **HNSW** e **IVF**.

Algoritmos Supervisionados - Extração de padrões

Os algoritmos de machine learning entendem dados numéricos estruturados. O pré-processamento realiza as **transformações necessárias** para levar a informação não-estruturada do domínio de imagem, texto, áudio, etc para o domínio numérico com estrutura padrão.

0,758	0,001	0,943	0,758	0,84	0,924
0,34	0,014	0,536	0,34	0,416	0,777
0,074	0,002	0,327	0,074	0,121	0,725
0,089	0,007	0,462	0,089	0,15	0,834
0,918	0,67	0,542	0,918	0,681	0,675
0,107	0,012	0,346	0,107	0,163	0,675
0,22	0,008	0,462	0,22	0,298	0,772
0,019	0,005	0,425	0,019	0,036	0,824
0,242	0,012	0,455	0,242	0,316	0,805
0,496	0,046	0,55	0,496	0,522	0,778




Entropia e Ganho de Informação



Algoritmos Supervisionados - Entropia

A **Entropia** é a medida do **grau de desordem** de um sistema, é uma grandeza física que está relacionada com a Segunda Lei da Termodinâmica e que tende a aumentar naturalmente no Universo.

A **entropia** é normalmente usada na teoria da informação para **medir a pureza ou impureza** de um determinado conjunto.




Algoritmos Supervisionados - Entropia

Considerando um **problema de classificação binária** e dado um grande conjunto de exemplos, como selecionamos um atributo para dividi-los de maneira informativa?


- **Classes:** Sim ou Não
- **Features:** Cor da cabeça, Cor do Corpo

Classes

Features



Algoritmos Supervisionados - Entropia



Entropia é uma medida normalizada **entre 0 e 1** e indica a pureza do grupo:

$$Entropia(S) = \sum_{i=1}^c -p_i \log_2(p_i)$$

Algoritmos Supervisionados - Segmentação



- **Atributos raramente dividem um grupo perfeitamente**, mesmo que um subgrupo seja puro, o outro pode não ser. (ver corpo=roxo)
- **Os atributos nem sempre são binários**, muitos são **categóricos** com vários valores distintos. Como podemos compará-los?
- **Alguns atributos assumem valores numéricos** (contínuos ou inteiros). Faz sentido fazer um segmento para cada valor numérico? **Como devemos pensar em criar segmentações supervisionadas utilizando atributos numéricos?**

Algoritmos Supervisionados - Ganho de Informação




A entropia mede a desordem de um grupo e não se “aquele atributo” é bom ou não para reduzir essa desordem...

Para isso usamos o **Ganho de Informação (GI)**, que é uma medida do quanto um **atributo melhora** (diminui) a entropia ao longo de toda a segmentação que ele cria. Ou seja, é a variação da entropia do grupo original (pai) com as dos grupos criados (Filhos).

$$GI(S, A) = Entropia(S) - \sum_{i=1}^n p(a_i) * Entropia(a_i)$$



Algoritmos Supervisionados - Ganho de Informação




$$IG(\text{parent}, \text{children}) = \text{entropy}(\text{parent}) - [p(c_1) \times \text{entropy}(c_1) + p(c_2) \times \text{entropy}(c_2) + \dots]$$

Dado um **conjunto PAI** com 30 instâncias, 16 da classe 1 e 14 da classe 2.

Qual o ganho de informação se utilizamos a variável **Balance** = {Balance < 50K, Balance ≥ 50k}?

Algoritmos Supervisionados - Ganho de Informação



2. Entropia do nó pai

$$H_{\text{pai}} = -p_1 \log_2 p_1 - p_2 \log_2 p_2$$

$$H_{\text{pai}} = -(0.533 \log_2 0.533 + 0.467 \log_2 0.467)$$

$$H_{\text{pai}} \approx 0.996$$

3. Filhos após o split em Balance

a) Balance < 50K

- 13 instâncias (12 da classe 1, 1 da classe 2)

$$p_1 = 12/13 = 0.923, \quad p_2 = 1/13 = 0.077$$

$$H_{<50K} = -(0.923 \log_2 0.923 + 0.077 \log_2 0.077) \approx 0.391$$

b) Balance ≥ 50K

- 17 instâncias (4 da classe 1, 13 da classe 2)

$$p_1 = 4/17 = 0.235, \quad p_2 = 13/17 = 0.765$$

$$H_{\geq 50K} = -(0.235 \log_2 0.235 + 0.765 \log_2 0.765) \approx 0.779$$

4. Entropia ponderada dos filhos

$$H_{\text{filhos}} = \frac{13}{30} H_{<50K} + \frac{17}{30} H_{\geq 50K}$$


$$H_{\text{filhos}} = \frac{13}{30} (0.391) + \frac{17}{30} (0.779) \approx 0.616$$

5. Ganho de informação

$$IG = H_{\text{pai}} - H_{\text{filhos}} = 0.996 - 0.616 = 0.380$$

Algoritmos Supervisionados - Ganho de Informação

Entire population (30 instances)



Utilizando o mesmo conjunto PAI, mas agora segmentando pela variável **Residence** = {Própria, Alugada, Outros}.

Cálculos..

- $Entropia(Pai) = 0.99$
- $Entropia(Residência=Própria) = 0.54$
- $Entropia(Residência=Alugada) = 0.97$
- $Entropia(Residência=Outros) = 0.98$
- $GI(PAI, Residência) = 0.13$

Qual é a melhor variável?


Algoritmos Supervisionados - Ganho de Informação

O Ganho de Informação pode ser utilizado para selecionar e priorizar atributos. Quanto maior o GI melhor é o atributo para segmentar as instâncias pela classe. Ou seja, quanto maior o GI de um atributo mais discriminativo é ele.

GI é a base para construção de ~~Árvores~~ de Decisão, através do GI é possível identificar o melhor atributo e as melhores partições para compor uma boa árvore.

$$GI(S, A) = Entropia(S) - \sum_{i=1}^n p(a_i) * Entropia(a_i)$$

Algoritmos Supervisionados - Árvore de Decisão




Algoritmos Supervisionados - Árvore de Decisão

As árvores de decisão são um dos algoritmos de ML mais versáteis, são compostas por **nó**, **ramo**, **folha** e **regra**

- são fáceis de entender e interpretar,
- o processo de **classificação** é **transparente** (caixa-branca) e
- elas podem lidar facilmente com atributos numéricos e categóricos.



- Classify 'John Doe'

- Balance=115K, Employed=No, and Age=40



Algoritmos Supervisionados - Árvore de Decisão

A **fronteira de decisão** de uma Árvore de Decisão é **não-linear**, segue a estratégia de “dividir para conquistar” e **cria subespaços no espaço de atributos** para classificar uma instância a partir da regra. Por que a divisão do Balance = $\{<50K, \geq 50k\}$?



Algoritmos Supervisionados - Árvore de Decisão

Existem vários algoritmos para criar a árvore a partir dos dados rotulados (CART, ID3, C4.5, SLIQ, SPRINT...). Todos utilizam o conceito de “melhor divisão” para criação dos ramos para otimizar a árvore, o **Ganho de Informação** é um dos mais usados.

Pseudo código do C4.5:

1. Verifica por casos básicos (todo o conjunto já é homogêneo, GI é igual para todos..)
2. Para cada atributo ***a***
 - a. Calcula o Ganho de Informação pelo particionamento em ***a***
3. Seja o ***a_maior*** o atributo com maior ganho de informação
4. Cria um nó de decisão que particiona o conjunto de dados em ***a_maior***
5. Repetir nos subconjuntos obtidos através da divisão em ***a_maior***,

Algoritmos Supervisionados - Árvore de Decisão



Dependendo da quantidade de instâncias e parâmetros, a árvore pode tomar proporções não esperadas. No geral os algoritmos de árvore **definem alguns critérios de paradas**:

- Quando todos os exemplos pertencem na **mesma classe**;
- Quando todos os exemplos têm os **mesmos valores dos atributos** (mas diferentes classes)
- Quando o número de **exemplos é inferior a certo limite**;
- Quando o **mérito** de todos os possíveis testes de partição **é muito baixo**;
- Quando a **profundidade** da árvore **exceder um limite**;

Os maiores problemas de uma Árvore de Decisão são o seu **rápido crescimento** (exponencial), **tamanho** e a facilidade em **gerar overfitting**.

Algoritmos Supervisionados - Árvore de Decisão



Usando um dataset de **churn**, com **4922** registros e **21** columns:

(4922, 21)

tService	OnlineSecurity	OnlineBackup	DeviceProtection	TechSupport	StreamingTV	StreamingMovies	Contract	PaperlessBilling	PaymentMethod	MonthlyCharges	TotalCharges	Churn
ber optic	No	No	No	No	No	Yes	Month-to-month	Yes	Electronic check	85.45	1451.60	1
DSL	Yes	Yes	Yes	No	Yes	Yes	Month-to-month	Yes	Bank transfer (automatic)	59.45	1884.65	0
No	No internet service	No internet service	No internet service	No internet service	No internet service	No internet service	Two year	No	Mailed check	19.60	331.60	0
DSL	No	Yes	No	Yes	No	No	One year	Yes	Mailed check	54.65	3134.70	0
ber optic	No	No	No	Yes	Yes	Yes	Month-to-month	Yes	Electronic check	94.45	1511.20	1



Algoritmos Supervisionados - Árvore de Decisão

Gerando uma árvore de profundidade = 3



Algoritmos Supervisionados - Árvore de Decisão

Gerando uma árvore sem restrições..



PODER JUDICIÁRIO

Tribunal de Justiça do Estado de Goiás



Programa de
Residência em TI

Algoritmos Supervisionados - Árvore de Decisão

A parametrização de uma árvore de decisão é **MUITO** importante, principalmente o *max_features*, *max_depth* e *min_samples_leaf*

`sklearn.tree.DecisionTreeClassifier`

```
class sklearn.tree. DecisionTreeClassifier (criterion='gini', splitter='best', max_depth=None,  
min_samples_split=2, min_samples_leaf=1, min_weight_fraction_leaf=0.0, max_features=None, random_state=None,  
max_leaf_nodes=None, min_impurity_decrease=0.0, min_impurity_split=None, class_weight=None, presort=False)
```

[\[source\]](#)

```
from sklearn.tree import DecisionTreeClassifier  
from sklearn.preprocessing import OrdinalEncoder  
# Pipeline Model  
model = Pipeline(steps = [  
    ('prepare', OrdinalEncoder()),  
    ('clf', DecisionTreeClassifier(criterion='entropy')),])  
  
model.fit(X_train, y_train)
```



Algoritmos Supervisionados - *Random Forest*



Uma variação da árvore de decisão é a **Floresta de Árvores** (Random Forest). Parte da ideia de “*se uma árvore é boa, uma floresta é melhor ainda...*”

A **Random Forest** é um **Ensemble**, ou comitê de árvores, e resolve o principal problema da Árvore de Decisão padrão. Ela:

- Generaliza melhor a solução final
- Em vez de profundidade, escala de forma horizontal com quantidade de árvores na floresta



Algoritmos Supervisionados - Random Forest

A parametrização de uma RandomForest também é **MUITO** importante, principalmente o `n_estimators`, `max_depth` e `min_samples_leaf`

3.2.4.3.1. `sklearn.ensemble.RandomForestClassifier`

```
class sklearn.ensemble. RandomForestClassifier (n_estimators='warn', criterion='gini', max_depth=None,
min_samples_split=2, min_samples_leaf=1, min_weight_fraction_leaf=0.0, max_features='auto',
max_leaf_nodes=None, min_impurity_decrease=0.0, min_impurity_split=None, bootstrap=True, oob_score=False,
n_jobs=None, random_state=None, verbose=0, warm_start=False, class_weight=None)
```

[\[source\]](#)

```
from sklearn.ensemble import RandomForestClassifier
from sklearn.preprocessing import OrdinalEncoder
# Pipeline Model
model = Pipeline(steps = [
    ('prepare', OrdinalEncoder()),
    ('clf', RandomForestClassifier(criterion='entropy', n_estimators=100)),])

model.fit(X_train, y_train)
```

<https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html>

Métricas de Avaliação

Regression

- MSPE
- MSAE
- R Square
- Adjusted R Square

Classification

- Precision-Recall
- ROC-AUC
- Accuracy
- Log-Loss

Unsupervised Models

- Rand Index
- Mutual Information

Others

- CV Error
- Heuristic methods to find K
- BLEU Score (NLP)

Métricas de Avaliação - Regressão

Métricas de Avaliação em Regressão utilizam o conceito de erro ou loss.

- Erro: a diferença entre o que foi predito e o valor real.
- Loss: medida quantificada de quão ruim é obter um erro de um determinado tamanho / direção.

O erro é utilizado na métrica de avaliação e a loss é uma função que queremos minimizar.

Quanto **menor** melhor. Variação de 0 a infinito.

Métricas de Avaliação - Regressão

MAE: *Mean Absolute Error*

- Erro Médio Absoluto.
- Dá **menos peso aos outliers**.
- Está na **mesma escala** que os dados.
- Fornece poucos *insights* sobre o erro ao comparar dados de escalas diferentes.

$$\frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Métricas de Avaliação - Regressão

MAPE: *Mean Absolute Percentage Error*

- Erro de Porcentagem Média Absoluta.
- Permite que o erro seja comparado entre dados com **escalas diferentes**.
- Se o valor esperado for **zero** para um item, não há como computar o erro e tal item **não é considerado**.
- Coloca uma penalidade maior em **erros negativos**.

$$\frac{100}{n} \sum_i^n \frac{y_i - \hat{y}_i}{y_i}$$

https://scikit-learn.org/dev/modules/generated/sklearn.metrics.mean_absolute_percentage_error.html

Métricas de Avaliação - Regressão

MSE: *Mean Squared Error*

- Erro Quadrático Médio.
- O erro não é apresentado na mesma escala dos dados (visto que eleva ao quadrado).
- Dá mais importância à **erros maiores**.

$$\frac{1}{n} \sum_i^n (y_i - \hat{y}_i)^2$$

https://scikit-learn.org/stable/modules/generated/sklearn.metrics.mean_squared_error.html

Métricas de Avaliação - Regressão

RMSE: *Root Mean Squared Error*

- Raiz do Erro Quadrático Médio.
- Nada mais é que a **raiz quadrada** do MSE.
- Volta o erro para a **escala** das features.
- Será sempre maior ou igual ao MAE (na mesma escala).

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{j=1}^n (y_j - \hat{y}_j)^2}$$

https://scikit-learn.org/stable/modules/generated/sklearn.metrics.mean_squared_error.html

Métricas de Avaliação - Classificação


- Métricas de Avaliação em Classificação são **discretas** e avaliam a quantidade de erros e acertos e não o erro médio.
- Apesar de não trabalharem com o erro de fato, durante o treinamento também existe uma função que queremos minimizar (ou **loss**).
- Normalmente as métricas estão relacionadas ao acerto. Ou seja, quanto **maior** melhor, variando entre 0 e 1.

Métricas de Avaliação - Classificação

Matriz de Confusão

- Verdadeiros Positivos
- Verdadeiros Negativos
- Falsos Positivos
- Falsos Negativos

		True Class	
		Positive	Negative
Predicted Class	Positive	TP	FP
	Negative	FN	TN



https://scikit-learn.org/stable/modules/generated/sklearn.metrics.confusion_matrix.html

Métricas de Avaliação - Classificação

Acurácia

- De todos os itens, quantos foram classificados corretamente?
- (Verdadeiros Positivos + Verdadeiros Negativos) / Total de itens.

		Actual	
		Positives(1)	Negatives(0)
Predicted	Positives(1)	TP	FP
	Negatives(0)	FN	TN

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{FP} + \text{FN} + \text{TN}}$$

https://scikit-learn.org/stable/modules/generated/sklearn.metrics.accuracy_score.html

Métricas de Avaliação - Classificação

Precisão (precision)


- Quantos dos itens selecionados são relevantes?
- Verdadeiros Positivos / (Verdadeiros Positivos + Falsos Positivos)

Abrangência (recall)

- Quantos itens relevantes foram selecionados?
- Verdadeiros Positivos / (Verdadeiros Positivos + Falsos Negativos)

https://scikit-learn.org/stable/modules/generated/sklearn.metrics.precision_score.html

https://scikit-learn.org/stable/modules/generated/sklearn.metrics.recall_score.html



How many selected
items are relevant?

$$\text{Precision} = \frac{\text{true positives}}{\text{true positives} + \text{false positives}}$$

How many relevant
items are selected?

$$\text{Recall} = \frac{\text{true positives}}{\text{true positives} + \text{false negatives}}$$


Métricas de Avaliação - Classificação

F1-Score

- Mais usado quando se quer dar mais importância aos negativos e falsos positivos.
- Melhor que acurácia quando o dataset está desbalanceado.

$$F_1\text{-score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2TP}{2TP + FP + FN}$$

https://scikit-learn.org/stable/modules/generated/sklearn.metrics.f1_score.html



How many selected items are relevant?

$$\text{Precision} = \frac{\text{true positives}}{\text{true positives} + \text{false positives}}$$

How many relevant items are selected?

$$\text{Recall} = \frac{\text{true positives}}{\text{true positives} + \text{false negatives}}$$

Atividades

1. Analisar o Notebook do Titanic e modificá-lo em busca de melhorar o resultado do modelo de *machine learning*.
2. Reproduza os passos apresentados no Notebook sobre RAG em Bancos de Dados Multimodais utilizando outra fonte de dados.