



APRENDIZAGEM DE MÁQUINA

Otávio Calaça Xavier



INF

INSTITUTO DE
INFORMÁTICA



UFG

UNIVERSIDADE
FEDERAL DE GOIÁS



PODER JUDICIÁRIO

Tribunal de Justiça do Estado de Goiás



Programa de
Residência em TI

Aula 5

Aprendizado Semi e Auto Supervisionado

INF

INSTITUTO DE
INFORMÁTICA



UFG
UNIVERSIDADE
FEDERAL DE GOIÁS



PODER JUDICIÁRIO

Tribunal de Justiça do Estado de Goiás



Programa de
Residência em TI

Objetivos da Aula

- Entender os conceitos de **semi** e **auto-supervisão**
- Comparar com aprendizado supervisionado e não supervisionado
- Explorar **casos de uso reais** e motivações
- Aplicar exemplos práticos simples em Python
- Discutir vantagens e limitações

Relembrando os Tipos de Aprendizado

Tipo	Rótulos	Exemplo
Supervisionado	✓ Todos	Classificação de e-mails
Não supervisionado	✗ Nenhum	Agrupar documentos
Semi-supervisionado	🖱️ Alguns	Pseudo-rotulagem
Auto-supervisionado	🤖 Gera seus próprios rótulos	Máscara e predição de partes

Aprendizado Semi-Supervisionado

- Usa **poucos dados rotulados** e muitos **não rotulados**
- Aprimora o modelo combinando **informação supervisionada e estrutura dos dados**
- Exemplo: pseudo-rotulagem (usar previsões como novos rótulos)
- Aplicações: detecção de fraudes, classificação de textos
- Reduz custo de anotação manual
- Combina o melhor de dois mundos: **supervisionado + não supervisionado**


Exemplo Prático: Pseudo-Labeling

- Exemplo

```
X, y = make_classification(  
    n_samples=300, n_features=2, n_redundant=0,  
    n_clusters_per_class=1, random_state=42  
)  
y[100:] = -1 # dados não rotulados  
# Plot inicial  
plt.scatter(X[y==-1, 0], X[y==-1, 1], c='lightgray', label='Não rotulados')  
plt.scatter(X[y==0, 0], X[y==0, 1], c='blue', label='Classe 0')  
plt.scatter(X[y==1, 0], X[y==1, 1], c='orange', label='Classe 1')  
plt.legend()  
plt.title("Dados rotulados e não rotulados")  
plt.show()
```

Exemplo Prático: Pseudo-Labeling

- Exemplo



Exemplo Prático: Pseudo-Labeling

- Exemplo


```
# Treinar modelo semi-supervisionado
model = SelfTrainingClassifier(RandomForestClassifier(), threshold=0.8)
model.fit(X, y)

# Predições finais
y_pred = model.predict(X)

# Plot resultado
plt.scatter(X[:,0], X[:,1], c=y_pred, cmap='coolwarm', alpha=0.7)
plt.title("Dados após pseudo-rotulagem")
plt.show()
```


Exemplo Prático: Pseudo-Labeling

- Exemplo



Por que usar aprendizado semi-supervisionado



- Rotular dados é caro e demorado.
- Muitos dados não rotulados disponíveis (textos, imagens, registros).
- O semi-supervisionado nasce para aproveitar essa abundância.

“Poucos rótulos, muitos dados – e um modelo que aprende a usar a estrutura dos dados para generalizar melhor.”

Três abordagens principais



Abordagem	Ideia central	Exemplos / Técnicas
Baseada em Consistência	Um mesmo exemplo deve gerar previsões estáveis mesmo após pequenas perturbações	<i>Mean Teacher, Virtual Adversarial Training</i>
Baseada em Pseudo-rotulagem	O modelo gera rótulos artificiais confiáveis e reaprende com eles	<i>Self-Training, FixMatch</i>
Baseada em Grafos	Usa similaridade entre amostras para propagar rótulos no grafo	<i>Label Propagation, Graph SSL</i>

Pseudo-rotulagem em mais detalhes



- O modelo supervisionado inicial faz previsões para exemplos não rotulados.
- Os exemplos com **alta confiança** são adicionados ao conjunto de treino.
- O modelo é re-treinado e o processo se repete.
- Risco: **erro acumulativo** (propagação de rótulos incorretos).



Semi-supervisionado + Representações (Deep SSL)



- Nos modelos modernos (CNNs, Transformers), o semi-supervisionado se conecta com **aprendizado de representações**:
 - O modelo é treinado com tarefas simples (auto-supervisão),
 - Depois refinado com poucos rótulos.
- Exemplos:
 - **SimCLR** ou **BYOL** para imagens, **BERT** para texto.



Conexões entre os tipos de aprendizado



- **Auto-supervisionado** → gera representações (pré-treinamento).
- **Semi-supervisionado** → refina com rótulos reais (fine-tuning).
- **Não supervisionado** → estrutura os dados.
- Juntos, formam a base dos sistemas **neuro-simbólicos e RAGs modernos**, que integram aprendizado, conhecimento e raciocínio.



Aprendizado Auto-Supervisionado



- Cria **tarefas de pré-treinamento** com rótulos gerados automaticamente
- Aprende **representações úteis** dos dados
- Exemplo: prever a próxima palavra ou parte oculta da entrada
- Muito usado em **LLMs (como o GPT), Visão Computacional e Voz**
- Reduz necessidade de dados rotulados
- Etapas: **pré-treinamento auto-supervisionado + ajuste supervisionado**



Exemplo Prático: Autoencoder (Auto-Supervisionado)



- Cria **tarefas de pré-treinamento** com rótulos gerados automaticamente
- Aprende **representações úteis** dos dados
- Exemplo: prever a próxima palavra ou parte oculta da entrada
- Muito usado em **LLMs (como o GPT), Visão Computacional e Voz**
- Reduz necessidade de dados rotulados
- Etapas: **pré-treinamento auto-supervisionado + ajuste supervisionado**



Exemplo Prático: Autoencoder

- Exemplo

```
from sklearn.datasets import fetch_openml
from sklearn.decomposition import PCA
import matplotlib.pyplot as plt


# Carregar dados do MNIST
mnist = fetch_openml('mnist_784', version=1, as_frame=False)
X = mnist.data[:5000] # usa subset pequeno para demo

# PCA = versão linear de um autoencoder
pca = PCA(n_components=32)
X_encoded = pca.fit_transform(X)
X_decoded = pca.inverse_transform(X_encoded)

# Mostrar exemplo de reconstrução
fig, ax = plt.subplots(1, 2, figsize=(6, 3))
ax[0].imshow(X[0].reshape(28, 28), cmap='gray')
ax[0].set_title("Original")
ax[1].imshow(X_decoded[0].reshape(28, 28), cmap='gray')
ax[1].set_title("Reconstruída")
plt.show()
```

Exemplo Prático: Autoencoder

- Exemplo



Autoencoder: como funciona?



-  **Entrada:** Recebe os dados originais (ex: imagem 28×28).
-  **Encoder:** Comprimi a informação, reduzindo dimensões.
-  **Camada Latente:** Representação compacta com as características mais relevantes.
-  **Decoder:** Reconstrói os dados a partir da representação latente.
-  **Erro de reconstrução:** Calcula a diferença entre a entrada e a saída.
-  **Aprendizado:** Ajusta os pesos para minimizar o erro e melhorar a reconstrução.

Atividade Prática



-  Atividade 1 – Semi-supervisionado (Self-Training) com SpamBase (OpenML id=44)
-  Atividade 2 – Auto-supervisionado (Autoencoder) com MNIST (Keras)
- Notebook:
<https://colab.research.google.com/drive/1jDnE4WiFGsflOT3jgFol3jwOrN250nN?usp=sharing>

