



APRENDIZAGEM DE MÁQUINA

Otávio Calaça Xavier



INF

INSTITUTO DE
INFORMÁTICA



UFG
UNIVERSIDADE
FEDERAL DE GOIÁS



PODER JUDICIÁRIO

Tribunal de Justiça do Estado de Goiás



Programa de
Residência em TI

Aula 6

Sistemas de Recomendação

INF

INSTITUTO DE
INFORMÁTICA



UFMG
UNIVERSIDADE
FEDERAL DE GOIÁS



PODER JUDICIÁRIO

Tribunal de Justiça do Estado de Goiás




Programa de
Residência em TI

Objetivos da Aula

- Regras de Associação
- Algoritmo Apriori
- Agregações Simples
- Filtragem Baseada em Conteúdo
- Filtragem Colaborativa

Regras de Associação



Regras de Associação



Cada registro corresponde à uma **transação** contendo vários items.

Frequent Itemsets são os conjuntos de itens que aparecem com frequência nas transações.

A partir dos conjuntos de itens, é possível extrair as **regras de associação**.

ID	Items
1	{Bread, Milk}
2	{Bread, Diapers , Beer , Eggs}
3	{Milk, Diapers , Beer , Cola}
4	{Bread, Milk, Diapers , Beer }
5	{Bread, Milk, Diapers, Cola}
...	...

market
basket
transactions

{Diapers, Beer}

Example of a frequent itemset

{Diapers} → {Beer}

Example of an association rule

Regras de Associação



Definição

- Seja $I = \{i_1, i_2, \dots, i_n\}$ um conjunto de n atributos binários chamados de itens;
- Seja $D = \{t_1, t_2, \dots, t_m\}$ um conjunto de transações;
- Cada transação em D tem um Id único e um subconjunto dos itens em I .
- Uma regra de associação é definida como uma implicação na forma:

$$X \Rightarrow Y, \text{ onde } X, Y \subseteq I$$

- Por exemplo, se $I = \{\text{leite, pão, arroz, feijão, óleo}\}$, $\{\text{arroz, feijão}\} \Rightarrow \{\text{óleo}\}$ pode ser uma regra de associação.
- Em uma regra de associação $X \Rightarrow Y$, X é chamado antecedente e Y consequente.

Regras de Associação

Com o propósito de selecionar as melhores regras de associação (e avaliá-las), alguns conceitos são definidos:

- Suporte
- Confiança
- Lift
- Convicção

Para as definições de cada um dos conceitos, considere:

- **X** e **Y**, conjuntos de itens (*itemsets*),
- **X** $\Rightarrow$ **Y**, uma regra de associação e
- **T** um conjunto de transações datas em um dataset.

Regras de Associação

Suporte: quão frequentemente o conjunto de itens aparece no *dataset*.

- O suporte de **X** em relação a **T** é definido como a proporção de transações **t** em **T** que contém o conjunto de itens **X**.

- Calcula a popularidade de **X** em **T**.

$$\text{supp}(X) = \frac{|\{t \in T; X \subseteq t\}|}{|T|}$$

- $\text{Suporte}(X) = (\text{Transações contendo } (X)) / (\text{Total de Transações})$

- Exemplo: $\text{Suporte}(\{\text{arroz, feijão}\}) = \frac{\text{Transações contendo } \{\text{arroz, feijão}\}}{\text{Total de transações}}$

Regras de Associação

Confiança: indica quão frequente a regra foi considerada verdadeira.

- A confiança de uma regra $X \Rightarrow Y$ em relação a um conjunto de transações T é a proporção das transações que contém X e também contém Y .
- Calcula a probabilidade de o conjunto de itens Y aparecer nas transações que possuem X .

$$\text{conf}(X \Rightarrow Y) = \text{supp}(X \cup Y) / \text{supp}(X)$$

Regras de Associação

Lift: a razão entre o suporte observado de uma regra $X \Rightarrow Y$ e o esperado considerando X e Y independentes.

- Em um dataset com transações relacionadas a vendas, o **lift** de uma regra refere-se ao aumento da taxa de venda de Y quando X é vendido, por exemplo.
- O lift igual a 1 implica que a probabilidade de ocorrência do antecedente (X) e o consequente (Y) são **independentes entre elas**. Logo, não pode ser definida uma regra.
- O lift maior que 1 diz que existe uma **dependência** entre os conjuntos de itens. Quanto maior o valor, mais **importante** é a regra no dataset.
- O lift menor que 1 implica em uma **correlação inversa** entre os conjuntos de itens. Ou seja, Y pode ser um **substituto** de X . Quando um é comprado, o outro não é.

$$\text{lift}(X \Rightarrow Y) = \frac{\text{supp}(X \cup Y)}{\text{supp}(X) \times \text{supp}(Y)}$$

Regras de Associação

Convicção: a razão da frequência esperada em que o antecedente(**X**) ocorre sem o consequente (**Y**) se **X** e **Y** forem independentes.

- Pode ser interpretada como a frequência em que a regra faria uma predição errada se a associação entre **X** e **Y** fosse puramente aleatória.

Exemplo: Uma Convicção de 1,3 mostra que a regra estaria incorreta 30% mais frequentemente (1,3 vezes) se a associação entre **X** e **Y** fosse puramente aleatória.

$$\text{conv}(X \Rightarrow Y) = \frac{1 - \text{supp}(Y)}{1 - \text{conf}(X \Rightarrow Y)}$$

Algoritmo Apriori

Usado para mineração de Conjuntos de Itens Frequentes (*frequent itemsets*) e para o aprendizado de regras de associação.

Identificar os itens individuais frequentes no *dataset* e ir estendendo a conjuntos de itens cada vez maiores, desde que esses conjuntos de itens apareçam com frequência suficiente no *dataset* (suporte).

Os Conjuntos de Itens Frequentes determinados pelo Apriori podem ser usados para encontrar regras de associação.

Algoritmo Apriori - 1ª Iteração

Exemplo Suporte = 2

- Pegar apenas os conjuntos de itens que contenham suporte maior que 2.

C1

TID	Items
T1	1 3 4
T2	2 3 5
T3	1 2 3 5
T4	2 5
T5	1 3 5



Itemset	Support
{1}	3
{2}	3
{3}	4
{4}	1
{5}	4

Algoritmo Apriori - 1ª Iteração

Exemplo Apriori – Suporte = 2

- Pegar apenas os conjuntos de itens que contenham suporte maior que 2.

C1

Itemset	Support
{1}	3
{2}	3
{3}	4
{4}	1
{5}	4



F1

Itemset	Support
{1}	3
{2}	3
{3}	4
{5}	4

Algoritmo Apriori - 2ª Iteração

Exemplo Apriori – Suporte = 2

- Pegar apenas os conjuntos de itens que contenham suporte maior que 2.

Only Items present in F1

C2

F2

TID	Items
T1	1 3 4
T2	2 3 5
T3	1 2 3 5
T4	2 5
T5	1 3 5



Itemset	Support
{1,2}	1
{1,3}	3
{1,5}	2
{2,3}	2
{2,5}	3
{3,5}	3



Itemset	Support
{1,3}	3
{1,5}	2
{2,3}	2
{2,5}	3
{3,5}	3

Algoritmo Apriori - Poda

Exemplo Apriori – Suporte = 2

- Na poda, os conjuntos de itens maiores que contenham **subconjuntos** de itens que não foram **considerados** na iteração anterior, são **descartados**.

C3

TID	Items
T1	1 3 4
T2	2 3 5
T3	1 2 3 5
T4	2 5
T5	1 3 5



Itemset	In F2?
{1,2,3}, {1,2}, {1,3}, {2,3}	NO
{1,2,5}, {1,2}, {1,5}, {2,5}	NO
{1,3,5}, {1,5}, {1,3}, {3,5}	YES
{2,3,5}, {2,3}, {2,5}, {3,5}	YES

Algoritmo Apriori - 3ª Iteração

Exemplo Apriori – Suporte = 2

- Pegar apenas os conjuntos de itens que contenham suporte maior que 2.

TID	Items
T1	1 3 4
T2	2 3 5
T3	1 2 3 5
T4	2 5
T5	1 3 5



F3

Itemset	Support
{1,3,5}	2
{2,3,5}	2

Algoritmo Apriori - 4ª Iteração

Exemplo Apriori – Suporte = 2

- Pegar apenas os conjuntos de itens que contenham suporte maior que 2.

TID	Items
T1	1 3 4
T2	2 3 5
T3	1 2 3 5
T4	2 5
T5	1 3 5



F3

Itemset	Support
{1,3,5}	2
{2,3,5}	2



C3

Itemset	Support
{1,2,3,5}	1

Algoritmo Apriori - Criação de Subconjuntos

Para cada subconjunto **S** de **I**, criar a regra: **S** $\Rightarrow$ (**I-S**)
Pegar apenas as regras que possuam uma **confiança** maior que um limiar definido.

F3

Itemset	Support
{1,3,5}	2
{2,3,5}	2

For **I** = {1,3,5}, subsets are {1,3}, {1,5}, {3,5}, {1}, {3}, {5}

For **I** = {2,3,5}, subsets are {2,3}, {2,5}, {3,5}, {2}, {3}, {5}

Algoritmo Apriori - Criação de Subconjuntos

Exemplo: **Confiança > 60%**

1. {1,3,5}

- ✓ Rule 1: $\{1,3\} \rightarrow (\{1,3,5\} - \{1,3\})$ means 1 & 3 $\rightarrow$ 5
Confidence = $\text{support}(1,3,5) / \text{support}(1,3) = 2/3 = 66.66\% > 60\%$
Rule 1 is selected
- ✓ Rule 2: $\{1,5\} \rightarrow (\{1,3,5\} - \{1,5\})$ means 1 & 5 $\rightarrow$ 3
Confidence = $\text{support}(1,3,5) / \text{support}(1,5) = 2/2 = 100\% > 60\%$
Rule 2 is selected
- ✓ Rule 3: $\{3,5\} \rightarrow (\{1,3,5\} - \{3,5\})$ means 3 & 5 $\rightarrow$ 1
Confidence = $\text{support}(1,3,5) / \text{support}(3,5) = 2/3 = 66.66\% > 60\%$
Rule 3 is selected

Algoritmo Apriori - Criação de Subconjuntos

Exemplo: **Confiança > 60%**

1. {1,3,5}

✓ Rule 4: {1} → ({1,3,5} - {1}) means 1 → 3 & 5

Confidence = $\text{support}(1,3,5) / \text{support}(1) = 2/3 = 66.66\% > 60\%$

Rule 4 is selected

✓ Rule 5: {3} → ({1,3,5} - {3}) means 3 → 1 & 5

Confidence = $\text{support}(1,3,5) / \text{support}(3) = 2/4 = 50\% < 60\%$

Rule 5 is rejected

✓ Rule 6: {5} → ({1,3,5} - {5}) means 5 → 1 & 3

Confidence = $\text{support}(1,3,5) / \text{support}(5) = 2/4 = 50\% < 60\%$

Rule 6 is rejected

Show me the code

—
... in Python, please!

<https://colab.research.google.com/drive/1yc811efRKXwhh6zT1KJ9Nlt4iQF7RPXa>

INF

INSTITUTO DE
INFORMÁTICA



UFMG
UNIVERSIDADE
FEDERAL DE GOIÁS



PODER JUDICIÁRIO

Tribunal de Justiça do Estado de Goiás



Programa de
Residência em TI

Aggregations Simple



Agregações Simples

Top 10.

Os mais populares.

Mais comprados.

Mais recentes.

Mais avaliados.

Melhor avaliados.

...



Editorial e Curadoria Manual

Lista de favoritos.

Avaliação do especialista.

Escolha do portal.

Melhores produtos.

...



Filtragem Demográfica

Usuários são divididos em grupos cujo critério de seleção é tomado com razão nos atributos demográficos, como idade, gênero e localização.

- Mulheres jovens de Goiás.
- Homens de terceira idade da classe C.
- Adolescentes das classes A e B da Região Metropolitana de Goiânia
- ...

Matriz de Utilidade

Combina o que com para quem recomendar.

Utilizada na maioria dos algoritmos baseados em similaridade.

Na maioria das vezes é muito esparsa.

	Avatar	LOTR	Matrix	Pirates
Alice	1		0.2	
Bob		0.5		0.3
Carol	0.2		1	
David				0.4

Principais questões

1. Como coletar os dados para colocar na matriz de utilidades?
2. Extrapolar os valores não conhecidos com base nos conhecidos.
3. Avaliação dos valores gerados.

	Avatar	LOTR	Matrix	Pirates
Alice	1		0.2	
Bob		0.5		0.3
Carol	0.2		1	
David				0.4

Principais questões

1. Como coletar os dados para colocar na matriz de utilidades?

Explícita

- Avaliações estruturadas dadas pelos próprios usuários (*rating*).
- Não escalam... muitos usuários não avaliam items.

Implícita

- Extrair as avaliações a partir de ações de usuários.
- Difícil colher avaliações negativas.

Principais questões


2. Extrapolar os valores não conhecidos com base nos conhecidos.

Problema: A matriz de utilidades é esparsa (muitas lacunas).

Início “a frio”:

- Novos itens não tem avaliações ainda.
- Novos usuários não tem histórico de consumo ainda.

Filtragem Baseada em Conteúdo




Filtragem Baseada em Conteúdo

Recomendar para o usuário itens similares àqueles que ele avaliou bem.

Exemplos:

- Filmes: mesmos atores, mesmo diretor, mesmo gênero, etc.
- Músicas: mesmo cantor, mesmo estilo musical, etc.
- Pessoas: amigos de amigos, muitos amigos em comum, etc.



Filtragem Baseada em Conteúdo

Para cada item, criar um **perfil do item**.

Um perfil é um conjunto de características (*features*).

- Filmes: atores, gênero, ano, diretor, etc.
- Notícias: palavras chave, categoria, data, etc.
- Pessoas: conjuntos de amigos.

Um vetor em que cada valor representa uma *feature*.

- Valores numéricos ou booleanos.

Filtragem Baseada em Conteúdo

User profile

- Após a construção dos perfis de itens, é necessário também construir os **perfis de usuários**.
- O perfil do usuário é baseado nos itens que ele avaliou e como os avaliou.
- Média ponderada dos perfis de itens avaliados.
- Pode ser normalizada pela média de avaliações dadas pelo usuário.

Filtragem Baseada em Conteúdo

Exemplo

- Recomendação de filmes.
- O perfil de item é um vetor informando a participação ou não dos atores.
- Usuário **X** assistiu **5 filmes**.

	ator A	ator B	ator C	ator D
Filme 1	1	0	0	0
Filme 2	1	0	1	0
Filme 3	0	1	0	1
Filme 4	0	1	1	1
Filme 5	0	1	1	0

Filtragem Baseada em Conteúdo

Exemplo

	ator A	ator B	ator C	ator D
Filme 1	1	0	0	0
Filme 2	1	0	1	0
Filme 3	0	1	0	1
Filme 4	0	1	0	1
Filme 5	0	1	1	0
Usuário X	2/5	3/5	2/5	2/5

Filtragem Baseada em Conteúdo

Exemplo

- Adicionando avaliações (1-5)

	ator A	ator B	ator C	ator D	Usuário X - aval.	Usuário X - norm.
Filme 1	1	0	0	0	3	0
Filme 2	1	0	1	0	5	2
Filme 3	0	1	0	1	1	-2
Filme 4	0	1	1	1	2	-1
Filme 5	0	1	1	0	4	1

- Opcional: normalizar pela média das avaliações do usuário
 $(3+5+1+2+4)/5 = 3.$

Filtragem Baseada em Conteúdo

Exemplo

- Cálculo do perfil do usuário X

	ator A	ator B	ator C	ator D	Usuário X - aval.	Usuário X - norm.
Filme 1	1	0	0	0	3	0
Filme 2	1	0	1	0	5	2
Filme 3	0	1	0	1	1	-2
Filme 4	0	1	1	1	2	-1
Filme 5	0	1	1	0	4	1
Usuário X	$(0+2)/2$	$(-2-1+1)/3$	$(2-1+1)/3$	$(-2-1)/2$		



Filtragem Baseada em Conteúdo

Exemplo


- Cálculo do perfil do usuário X

	ator A	ator B	ator C	ator D
Filme 1	1	0	0	0
Filme 2	1	0	1	0
Filme 3	0	1	0	1
Filme 4	0	1	1	1
Filme 5	0	1	1	0
Usuário X	1	-0.67	0.67	-1.5
Usuario Y	2	-1.3	1.3	-3



Filtragem Colaborativa

COLLABORATIVE FILTERING



Filtragem Colaborativa

- Recomendar itens para o usuário com base na similaridade dele para com outros usuários.
- Dado o usuário x ,
- Encontrar um conjunto de usuários N que as avaliações são similares as avaliações do usuário x
- Estimar as avaliações do usuário x baseando-se nas avaliações dos usuários em N .

Filtragem Colaborativa

Exemplo

- 4 usuários e 6 filmes

	HP 1	HP 2	HP 3	Crep.	SW 1	SW 2	SW 3
Usuário A	4			5	1		
Usuário B	5	5	4				
Usuário C				2	4	5	
Usuário D		3					3

- Nesse caso, a similaridade de cossenos considerará as lacunas como zeros.
- **Problema:** o valor zero está associado à uma avaliação ruim.

Filtragem Colaborativa

Exemplo

	HP 1	HP 2	HP 3	Crep.	SW 1	SW 2	SW 3
Usuário A	4			5	1		
Usuário B	5	5	4				
Usuário C				2	4	5	
Usuário D		3					3

- Utilizar a **similaridade de cossenos centrada**.

Filtragem Colaborativa

Exemplo

	HP 1	HP 2	HP 3	Crep.	SW 1	SW 2	SW 3	Média
Usuário A	4			5	1			10/3
Usuário B	5	5	4					14/3
Usuário C				2	4	5		11/3
Usuário D		3					3	3

- Utilizar a **similaridade de cossenos centrada**.
- Pegue a média de cada usuário.

Filtragem Colaborativa

Exemplo

	HP 1	HP 2	HP 3	Crep.	SW 1	SW 2	SW 3	Média
Usuário A	4			5	1			10/3
Usuário B	5	5	4					14/3
Usuário C				2	4	5		11/3
Usuário D		3					3	3

- Utilizar a **similaridade de cossenos centrada**.
 - Pegue a média de cada usuário.
 - Subtraia, do valor original, a média.

Filtragem Colaborativa

Exemplo

	HP 1	HP 2	HP 3	Crep.	SW 1	SW 2	SW 3	Média
Usuário A	2/3			5/3	-7/3			10/3
Usuário B	1/3	1/3	-2/3					14/3
Usuário C				-5/3	1/3	4/3		11/3
Usuário D		0					0	3

- Utilizar a **similaridade de cossenos centrada**.
 - Pegue a média de cada usuário.
 - Subtraia, do valor original, a média.

Filtragem Colaborativa

Exemplo

	HP 1	HP 2	HP 3	Crep.	SW 1	SW 2	SW 3	Média
Usuário A	2/3			5/3	-7/3			10/3
Usuário B	1/3	1/3	-2/3					14/3
Usuário C				-5/3	1/3	4/3		11/3
Usuário D		0					0	3

- Utilizar a **similaridade de cossenos centrada**.
 - Captura melhor a intuição.
 - Lacunas são tratadas como a média do usuário.
 - Trata a subjetividade na avaliação.


Filtragem Colaborativa

Exemplo

	HP 1	HP 2	HP 3	Crep.	SW 1	SW 2	SW 3	Média
Usuário A	2/3			5/3	-7/3			10/3
Usuário B	1/3	1/3	-2/3					14/3
Usuário C				-5/3	1/3	4/3		11/3
Usuário D		0					0	3

- Utilizar a **similaridade de cossenos centrada**.
- Também conhecida como **Correlação de Pearson**.

Filtragem Colaborativa



Filtragem Colaborativa

User-user vs Item-Item

- Na filtragem colaborativa user-user, como visto, é realizada a similaridade entre usuários, de acordo com as avaliações que eles deram para os itens.
- Já na filtragem colaborativa item-item, a similaridade calculada é entre os itens, levando em conta as avaliações dos usuários.

Filtragem Colaborativa

User-User

	HP 1	HP 2	HP 3	Crep.	SW 1	SW 2	SW 3	Média
Usuário A	0.67			1.67	-2.33			3.33
Usuário B	0.33	0.33	-0.67	?				4.67
Usuário C				-1.67	0.33	1.33		3.67
Usuário D		0					0	3

- Pegue os **N** usuários mais similares e faz a média das avaliações deles para o filme em questão.
- Mais similares ao Usuário B => **0.43** Usuário D; **0.37** Usuário A
- Calculando ... $(0.43 \cdot 0 + 0.37 \cdot 1.67) / (0.43 + 0.37) = \mathbf{0.77}$

Retirando normalização: **5**

Filtragem Colaborativa

Item-Item

	HP 1	HP 2	HP 3	Crep.	SW 1	SW 2	SW 3	Média
Usuário A	0.67			1.67	-2.33			3.33
Usuário B	0.33	0.33	-0.67	?				4.67
Usuário C				-1.67	0.33	1.33		3.67
Usuário D		0					0	3

- Pegue os **N** itens mais similares (pelas avaliações) e faz a média das avaliações do usuário para eles.
- Mais similares ao Crepúsculo => **0.63** HP 1; **0.0** HP 2
- Calculando ... $(0.63 \cdot 0.33 + 0 \cdot 0.33) / (0.33 + 0.33) = \mathbf{0.31}$

Retirando normalização: **4.98**