

Projeção da Taxa de Congestionamento

Justiça Estadual (GO)

Residência em TI - Tribunal de Justiça de Goiás

Fase: CRISP-DM Modeling & Evaluation

Júlio César Prado Souza Rodrigues e Lays de Freitas Melo | 15/12/2025

Entendimento do Negócio



Contexto

O TJ-GO necessita otimizar a alocação de recursos (magistrados e servidores) para garantir a celeridade processual e reduzir gargalos.



A Dor

Falta de visibilidade futura.
Decisões reativas baseadas apenas em dados passados, sem antecipar a piora de índices em comarcas específicas.



Objetivo

Desenvolver modelo preditivo da **Taxa de Congestionamento** (horizontes de 3, 6 e 12 meses) para todas as unidades jurisdicionais.

Pipeline de Dados e Pré-processamento

📉 SANEAMENTO & AGREGAÇÃO

- **Agregação Temporal:** Consolidação de 3.2M de registros transacionais em séries temporais mensais (grouped by Comarca/Serventia).
- **Filtro de Ruído:** Exclusão de CEJUSCs (alta volatilidade em mutirões) e Unidades com < 10 mov/mês.
- **Resultado:** Redução de 571k para 22k registros de alta qualidade (Curadoria de Dados).

🧪 ENGENHARIA DE FEATURES

Definição da Target:

$$Tx = \frac{\text{Pendentes}}{\text{Pendentes} + \text{Baixados}} \times 100$$

Transformação: Conversão da variável temporal de `datetime` para formato `ordinal` para viabilizar o cálculo de coeficientes angulares na Regressão Linear.

Estratégia de Modelagem (Baseline)

ABORDAGEM

Implementação de **Regressão Linear Simples (OLS)**.

Uma estratégia de "Um Modelo por Unidade",
treinando regressores independentes para cada uma
das >500 unidades judiciárias do estado.

POR QUE REGRESSÃO LINEAR?

- **Interpretação:** Baseline clara para entender tendências (inclinação da reta).
- **Inércia:** A taxa de congestionamento possui forte componente inercial, bem capturada pelo beta da regressão.
- **Parsimônia:** Evita overfitting em séries curtas (2022-2025) onde LSTMs poderiam "alucinar".
- **Escalabilidade:** Custo computacional baixo para retreino frequente.

Avaliação Global (Validação)

Performance no conjunto de validação (Hold-out dos últimos 3 meses)

11.86%

MAE (ERRO MÉDIO ABSOLUTO)

Erro médio aceitável para uma baseline inicial.

22.23%

RMSE (RAIZ DO ERRO QUADRÁTICO)

Penalização severa por outliers (quebras estruturais).

Análise de Resíduos e Diagnóstico



Variância heterogênea

Observada em unidades menores.

A variância do erro tende a aumentar com o tempo, indicando instabilidade em comarcas de baixo volume.



Outliers Críticos

Gabinetes de Desembargadores apresentaram erros de ~95 p.p. devido a bloqueios repentinos de fluxo que uma reta linear não prevê.




Multicolinearidade

Não detectada (Abordagem Univariada). O coeficiente angular temporal mostrou-se estatisticamente significativo nas unidades estáveis.

Visualização do Fit (Ex: 3ª Vara de Família)

Análise do Comportamento

- **Histórico (Linha Azul):** Demonstra a evolução real da taxa, com leve sazonalidade.
- **Predição (Linha Vermelha):** A Regressão captura a tendência direcional de alta.
- **Conclusão:** Para unidades comportadas, o modelo prevê corretamente taxas acima de 90% para o final de 2025.



Conclusões e Próximos Passos

🚩 CONCLUSÕES DO CICLO 1

- A Regressão Linear atua bem como "termômetro de tendência", mas ignora sazonalidade.
- O RMSE elevado confirma que um único algoritmo não resolve o problema de todas as unidades (ex: Gabinetes vs Varas).
- A limpeza de dados (CEJUSCs) foi vital para a estabilidade.

🗺️ PRÓXIMOS PASSOS

- **Modelos de Sazonalidade:** Testar Prophet ou Holt-Winters para capturar padrões mensais.
- **Variáveis Exógenas:** Incluir "Estoque Inicial" e "Novos Casos" (Lagged Features) em modelos baseados em árvore (XGBoost).
- **Deteção de Anomalias:** Alertar mudanças bruscas de comportamento.

Obrigado!

residencia.ti@tjgo.jus.br

